



Probabilidad y Estadística

Introducción a R

Lic. Constanza Rodolfo

2026

1 Introducción a R

2 Instalación

3 Ejemplo 1

4 Ejemplo 2

5 Paquetes

- Lenguaje interpretado
- Está orientado a análisis de datos basándose en vectores y data frame
- Vamos a usarlo para organizar datos, analizarlos y además hacer gráficos descriptivos

Introducción a R

Tipos atómicos que vamos a usar:

- numeric (double)
- character (string)
- logical (booleanos)

Estructuras de datos:

- Vectores. Constructor: *c*
- Matrices. Constructor: *matrix*
- Data frames. Constructor: *data.frame*
- Tablas. Constructor: *table*

¿Cómo vamos a usar R?

Instalando R también se instala una consola. Esta es útil, pero no es lo más práctico para el usuario.

Entonces vamos a usar RStudio que nos ofrece un entorno para usar R de forma más cómoda, visual y organizada.

Para descargar R tenemos los siguientes links:

- Windows: <https://cran.r-project.org/bin/windows/base/>
- Linux: <https://cran.r-project.org/bin/linux/>
- Mac: <https://cran.r-project.org/bin/macosx/>

Una vez descargado, se instala con las opciones por defecto.

Para descargar RStudio:

- <https://posit.co/download/rstudio-desktop/>

Ejemplo

A partir de la idea de que muchos estudiantes universitarios duermen menos de lo recomendado, se encuestó a un grupo de estudiantes de aproximadamente 20 años y se les preguntó cuántas horas duermen por noche, en promedio, durante la semana obteniéndose los siguientes datos (en horas):

8, 5, 7, 8,5, 5, 5,5, 6, 6, 6,5, 9, 7, 10, 7, 7,5, 8,
7,5, 4,5, 8, 7,5, 8,5, 9, 5, 9,5, 7, 6, 7, 8, 6,5, 4, 9

Analicemos estos datos ayudándonos de R.
Cargamos primero los datos en un vector:

```
suenio <- c(8, 5, 7, 8.5, 5, 5.5, 6, 6, 6.5, 9, 7, 10,  
  ↪ 7, 7.5, 8, 7.5, 4.5, 8, 7.5, 8.5, 9, 5, 9.5, 7, 6,  
  ↪ 7, 8, 6.5, 4, 9)
```

Ejemplo horas de sueño

Como estamos teniendo una variable cuantitativa, podríamos querer calcular las medidas de posición, de dispersión y de tendencia central. R trae funciones definidas para poder calcular todo esto:

```
length(suenio)    # cantidad de datos
summary(suenio)   # medidas de posicion
median(suenio)    # mediana
mean(suenio)      # media
sd(suenio)        # desvio estandar
var(suenio)       # varianza
```

Como dijimos antes, R nos va a facilitar graficar. ¿Qué gráficos podríamos hacer para el tipo de variable que tenemos?

Repaso: gráficos según el tipo de variable

Tipo de variable	Gráficos adecuados
Cualitativa nominal	Gráfico de barras, gráfico de sectores circulares (sólo si hay dos o tres categorías)
Cualitativa ordinal	Gráfico de barras ordenado (respetando orden de las categorías)
Cualitativa de respuesta múltiple	Gráfico de barras
Cuantitativa discreta	Gráfico de bastones, boxplot, gráfico de puntos, diagrama de tallo y hoja
Cuantitativa continua	Histograma, boxplot, diagrama de tallo y hoja
Temporal	Gráfico de líneas / serie temporal

Ejemplo horas de sueño

Nosotros estamos en el caso de una variable cuantitativa continua, así que podríamos hacer un histograma, un boxplot o un diagrama de tallo y hoja.

```
hist(suenio)           # histograma  
boxplot(suenio, horizontal = TRUE) # boxplot  
stem(suenio)           # tallo-hoja
```

Ejemplo

Queremos saber qué corredor de F1 fue el que más GP ganó durante el año 2025:

Piloto	Fecha	Gran Premio	Circuito
NORRIS Lando	16 marzo 2025	Australia	Melbourne
PIASTRI Oscar	23 marzo 2025	China	Shanghái
VERSTAPPEN Max	6 abril 2025	Japón	Suzuka
PIASTRI Oscar	13 abril 2025	Baréin	Sakhir
PIASTRI Oscar	20 abril 2025	Arabia Saudita	Yeda
PIASTRI Oscar	4 mayo 2025	Miami	Miami
VERSTAPPEN Max	18 mayo 2025	Emilia-Romaña	Imola
NORRIS Lando	25 mayo 2025	Mónaco	Monaco
PIASTRI Oscar	1 junio 2025	España	Barcelona
RUSSELL George	15 junio 2025	Canadá	Montreal
NORRIS Lando	29 junio 2025	Austria	Spielberg
NORRIS Lando	6 julio 2025	Gran Bretaña	Silverstone
PIASTRI Oscar	27 julio 2025	Bélgica	Spa-Francorchamps
NORRIS Lando	3 agosto 2025	Hungría	Hungaroring
PIASTRI Oscar	31 agosto 2025	Países Bajos	Zandvoort
VERSTAPPEN Max	7 septiembre 2025	Italia	Monza
VERSTAPPEN Max	21 septiembre 2025	Azerbaiyán	Bakú
RUSSELL George	5 octubre 2025	Singapur	Singapur
VERSTAPPEN Max	19 octubre 2025	Estados Unidos	Austin
NORRIS Lando	26 octubre 2025	Ciudad de México	Ciudad de Mexico
NORRIS Lando	9 noviembre 2025	São Paulo	Interlagos
VERSTAPPEN Max	22 noviembre 2025	Las Vegas	Las Vegas
VERSTAPPEN Max	30 noviembre 2025	Catar	Lusail
VERSTAPPEN Max	7 diciembre 2025	Abu Dabi	Yas Marina

Figura: Tabla extraída de Stats F1

Ejemplo F1

Vamos a usar R para poder analizar mejor estos datos.
Primero lo primero, ¿cómo cargamos estos datos en R?

```
datosF1 <- data.frame(  
  "ganador" = c("NORRIS Lando", "PIASTRI Oscar", "VERSTAPPEN Max", "PIASTRI Oscar",  
    "PIASTRI Oscar", "PIASTRI Oscar", "VERSTAPPEN Max", "NORRIS Lando",  
    "PIASTRI Oscar", "RUSSELL George", "NORRIS Lando", "NORRIS Lando",  
    "PIASTRI Oscar", "NORRIS Lando", "PIASTRI Oscar", "VERSTAPPEN Max",  
    "VERSTAPPEN Max", "RUSSELL George", "VERSTAPPEN Max", "NORRIS Lando",  
    "NORRIS Lando", "VERSTAPPEN Max", "VERSTAPPEN Max", "VERSTAPPEN Max"),  
  "fecha" = c("16 marzo 2025", "23 marzo 2025", "6 abril 2025", "13 abril 2025",  
    "20 abril 2025", "4 mayo 2025", "18 mayo 2025", "25 mayo 2025",  
    "1 junio 2025", "15 junio 2025", "29 junio 2025", "6 julio 2025",  
    "27 julio 2025", "3 agosto 2025", "31 agosto 2025", "7 septiembre 2025",  
    "21 septiembre 2025", "5 octubre 2025", "19 octubre 2025", "26 octubre 2025",  
    "9 noviembre 2025", "22 noviembre 2025", "30 noviembre 2025", "7 diciembre 2025"),  
  "gp" = c("Australia", "China", "Japón", "Baréin", "Arabia Saudita",  
    "Miami", "Emilia-Romaña", "Mónaco", "España", "Canadá",  
    "Austria", "Gran Bretaña", "Bélgica", "Hungría", "Países Bajos",  
    "Italia", "Azerbaiyán", "Singapur", "Estados Unidos",  
    "Ciudad de México", "São Paulo", "Las Vegas", "Catar", "Abu Dabi"),  
  "circuito" = c("Melbourne", "Shanghái", "Suzuka", "Sakhir", "Yeda",  
    "Miami", "Imola", "Monaco", "Barcelona", "Montreal",  
    "Spielberg", "Silverstone", "Spa-Francorchamps", "Hungaroring",  
    "Zandvoort", "Monza", "Bakú", "Singapur", "Austin",  
    "Ciudad de Mexico", "Interlagos", "Las Vegas", "Lusail", "Yas Marina")  
)
```

Ejemplo F1

Y si ahora ponemos `datosF1` en la consola, nos va a mostrar algo del estilo:

```
> datosF1
  ganador      fecha      gp      circuito
1  NORRIS Lando 16 marzo 2025 Australia Melbourne
2  PIASTRI Oscar 23 marzo 2025 China Shanghai
3  VERSTAPPEN Max 6 abril 2025 Japón Suzuka
4  PIASTRI Oscar 13 abril 2025 Baréin Sakhir
5  PIASTRI Oscar 20 abril 2025 Arabia Saudita Yeda
6  PIASTRI Oscar 4 mayo 2025 Miami Miami
7  VERSTAPPEN Max 18 mayo 2025 Emilia-Romaña Imola
8  NORRIS Lando 25 mayo 2025 Mónaco Monaco
9  PIASTRI Oscar 1 junio 2025 España Barcelona
10 RUSSELL George 15 junio 2025 Canadá Montreal
11 NORRIS Lando 29 junio 2025 Austria Spielberg
12 NORRIS Lando 6 julio 2025 Gran Bretaña Silverstone
13 PIASTRI Oscar 27 julio 2025 Bélgica Spa-Francorchamps
14 NORRIS Lando 3 agosto 2025 Hungría Hungaroring
15 PIASTRI Oscar 31 agosto 2025 Países Bajos Zandvoort
16 VERSTAPPEN Max 7 septiembre 2025 Italia Monza
17 VERSTAPPEN Max 21 septiembre 2025 Azerbaiyán Bakú
18 RUSSELL George 5 octubre 2025 Singapur Singapur
19 VERSTAPPEN Max 19 octubre 2025 Estados Unidos Austin
20 NORRIS Lando 26 octubre 2025 Ciudad de México Ciudad de México
21 NORRIS Lando 9 noviembre 2025 São Paulo Interlagos
22 VERSTAPPEN Max 22 noviembre 2025 Las Vegas Las Vegas
23 VERSTAPPEN Max 30 noviembre 2025 Catar Lusail
24 VERSTAPPEN Max 7 diciembre 2025 Abu Dabi Yas Marina
```

Ahora tenemos todos nuestros datos en un data frame. Si bien toda la información necesaria está en la tabla, para responder la pregunta "¿quién ganó más carreras?", sería más sencillo ver lo que tenemos en un gráfico.

Ejemplo F1

Entonces, ¿cómo hacemos en un gráfico de barras con las victorias por corredor?


Debemos hacer un gráfico de barras de la frecuencia absoluta de las apareciones de los nombres de los corredores en nuestro vector `ganador` del data frame `datosF1`. Los creadores de R ya pensaron en esto e hicieron una función especial para que no tengamos que contar a mano cada vez que se repite un mismo resultado.

```
frec_abs <- table(datosF1$ganador)

barplot(
  frec_abs,
  col = "pink",
  main = strsplit("Victorias de GP F1 por piloto; en
↪ el año 2025", split=";"),
  xlab = "Piloto",
  ylab = "Cantidad de victorias"
)
```

Ejemplo F1

Con esto vamos a ver que en extremo inferior derecho aparece un gráfico de barras de la forma:



Ya vimos que para ingresar 24 datos en R a mano puede parecer tedioso. Imagínense tener que ingresar ingresar cientos y cientos de datos a mano... no parece es algo práctico

Para facilitar esto, vamos a hacer uso de dos paquetes ya existentes que solucionan este problema:

- **readxl**: paquete que nos permite obtener un data frame a partir de un excel (archivo .xsl),
- **googlesheets4**: paquete que nos permite obtener un data frame a partir de una hoja de cálculo de google (pasando url, la hoja debe ser pública).

Instalación de paquetes: readxl

La primera vez, para instalar el paquete `readxl`, ejecutamos el comando:

```
install.packages("readxl")
```

y luego cada vez que se quiera usar se carga la librería:

```
library(readxl)  
  
data <- read_excel(path)
```

Instalación de paquetes: googlesheets4

Como con `readxl`, instalamos el paquete:

```
install.packages("googlesheets4")
```

y luego cada vez que se quiera usar se carga la librería:

```
library(googlesheets4)

# agregamos lo siguiente para que no intente
# autenticarse con una cuenta de google
gs4_deauth()
url = "https://docs.google.com/spreadsheets/d/
      1pTipGeejixmMf118aw6WbdBatUeo9cyRDVA_jvHF7ZQ
      /edit?usp=sharing"
mundial_2022 <- read_sheet(url)
```

Instalación de paquetes: ggplot2

Además, vamos a usar también el paquete `ggplot2` que nos brinda herramientas para poder diseñar gráficos más complejos. Instalamos el paquete:

```
install.packages("ggplot2")
```

y luego cada vez que se quiera usar se carga la librería:

```
library(ggplot2)
```