



Probabilidad y Estadística

Cadenas de Markov

Lic. Constanza Rodolfo

2026

- 1 Definición
- 2 Diagrama de transición y matriz
- 3 Clasificación de estados
- 4 Conjuntos cerrados e irreducibles
- 5 Comportamiento límite

No es de extrañar que el nombre *Markov* nos lleve directamente a recordar la **Propiedad Markoviana**:

Propiedad Markoviana

El futuro del proceso depende del pasado *únicamente* a través del estado presente:

$$P(X_{n+1} = j \mid X_0 = k_0, \dots, X_{n-1} = k_{n-1}, X_n = i) = P(X_{n+1} = j \mid X_n = i)$$

Esta propiedad juega un rol fundamental en la forma en que vamos a analizar este tipo particular de procesos.

Definición

Vamos a restringir nuestro estudio a procesos estocásticos donde la colección de variables aleatorias cumple con los siguientes requisitos:

- 1 El **espacio de estados** es discreto, i.e:

$$S = \{X_n(\omega) : n \in T, \omega \in \Omega\} \text{ es infinito numerable.}$$

- 2 El **espacio temporal** es un conjunto discreto.
- 3 Se cumple la **Propiedad Markoviana**.

Definición

Llamamos **Cadenas de Markov** (o Cadenas Markovianas), y denotamos $\{X_n\}$, a los procesos estocásticos que cumplen estas tres condiciones.

Observacion:

En bibliografías se las puede encontrar como *Cadenas de Markov a tiempo discreto*, ya que existen también a tiempo continuo (esto excede el alcance de la asignatura, ¡pero siempre están invitados a leer más al respecto!).


Diagrama de transición

En esta materia vamos a trabajar con **cadenas homogéneas**: aquellas en las que la probabilidad de pasar de un estado a otro *no depende del momento* en que nos encontramos, sino únicamente de los estados involucrados. Esto nos va a permitir trabajar las cadenas pensándolas como *grafos* y *matrices* que no cambian en el tiempo. Esto ya lo vimos para el proceso relacionado a número de éxitos, pero vamos a formalizarlo.

Definición

El **diagrama de transición** de una Cadena de Markov es un grafo dirigido donde:

- los **nodos** son los estados de la cadena,
- las **aristas** se etiquetan con la probabilidad de transición de un estado a otro en un paso.




Ejemplo 1: Servidor disponible/caído

Un servidor puede estar en dos estados: **Disponible** (D) o **Caído** (C).

- Si está disponible: sigue estando disponible con probabilidad 0,9 y cae con probabilidad 0,1;
- Si está caído: vuelve a estar disponible con probabilidad 0,6 y sigue caído con probabilidad 0,4.

Entonces, el grafo asociado a la cadena de Markov $\{X_n : \text{estado del servidor en el tiempo } n, n \in \mathbb{N}\}$ es




Ejemplo 2: Envío de un mail

El mail puede encontrarse en uno de los siguientes estados: **Listo** (L), **En tránsito** (T), **Rebotado** (R), **Entregado** (E).

Reglas de transición:

- Desde **L**: siempre pasa a T;
- Desde **T**: llega a E con probabilidad 0,9 y queda en R con prob. 0,1;
- Desde **R**: siempre vuelve a T;
- Desde **E**: permanece en E

Para la cadena de Markov $\{X_n : \text{estado del mail en el tiempo } n, n \in \mathbb{N}\}$ tenemos el grafo



Matriz de transición

Definición

La **matriz de transición** $M = (m_{ij})$ es la matriz cuadrada de tamaño $|S| \times |S|$ donde

$$m_{ij} = P(X_{n+1} = j \mid X_n = i) \quad \forall n \in \mathbb{N}$$


- Las **filas** indican el estado desde el que salimos; las **columnas**, el estado al que llegamos.
- Es análoga a una matriz de adyacencias, pero con *probabilidades* en lugar de 0 y 1.
- **Cada fila suma 1**: la fila i es la distribución de probabilidades del estado siguiente dado que hoy estamos en i .

Matrices estocásticas

Las matrices que cumplen que sus entradas son no negativas y que cada fila suma 1 se llaman **matrices estocásticas**. En particular, las matrices de transición de las Cadenas de Markov son matrices estocásticas.

Grafo y matriz — los dos ejemplos


Ejemplo 1: Servidor D/C



→

$$M = \begin{pmatrix} 0,9 & 0,1 \\ 0,6 & 0,4 \end{pmatrix}$$

Ejemplo 2: Envío de mail



→


$$M = \begin{pmatrix} 0 & 1 & 0 & 0 \\ 0 & 0 & 0,1 & 0,9 \\ 0 & 1 & 0 & 0 \\ 0 & 0 & 0 & 1 \end{pmatrix}$$

¿Y si queremos ir más de un paso?

Hasta ahora pensamos en $P(X_{n+1} = j \mid X_n = i)$: probabilidades de un solo paso. ¿Qué pasa si queremos llegar a un estado en **varios pasos**?

$$P(X_{n+m} = j \mid X_n = i) = ?$$


Veamos qué pasa en el ejemplo del servidor.



Calculemos la probabilidad de que el servidor se caiga en 2 pasos siendo que está disponible:

$$P(X_2 = C \mid X_0 = D) = ?$$

¿Y si queremos ir más de un paso?




Tenemos dos posibilidades:

- $D \rightarrow D \rightarrow C$
- $D \rightarrow C \rightarrow C$

Calculando esto tenemos

$$\begin{aligned} P(X_2 = C \mid X_0 = D) &= P(X_2 = C \mid X_1 = D) * P(X_1 = D \mid X_0 = D) \\ &\quad + P(X_2 = C \mid X_1 = C) * P(X_1 = C \mid X_0 = D) \\ &= m_{12} * m_{11} + m_{22} * m_{12} \\ &= 0,1 * 0,9 + 0,4 * 0,1 = 0,13 \end{aligned}$$

¿Y si queremos ir más de un paso?



Entonces tenemos

$$P(X_2 = C \mid X_0 = D) = 0,13$$

Pero fíjense lo siguiente:

$$M = \begin{pmatrix} 0,9 & 0,1 \\ 0,6 & 0,4 \end{pmatrix} \quad \Longrightarrow \quad M^2 = \begin{pmatrix} 0,87 & 0,13 \\ 0,78 & 0,22 \end{pmatrix}$$

Donde vemos que $M^2_{12} = 0,13$ coincidiendo la posición con los estados de “partida” y de “llegada”...

¿Y si queremos ir más de un paso?

Esto no es una coincidencia, es un resultado muy importante de las Cadenas de Markov:

Proposición

La **matriz de transición en m pasos** es la m -ésima potencia de la matriz de transición en 1 paso:

$$M^{(m)} = M^m.$$

Es decir,

$$P(X_m = j \mid X_0 = i) = M^{(m)}_{ij}$$


Aclaración: Esto no es una propiedad que cumple cualquier cadena, es de vital importancia que sea homogénea y además que cumpla la propiedad de Markov.

*Recordemos que las cadenas **homogéneas** son aquellas donde la matriz M es siempre la misma independientemente del momento n .*

Estados especiales


Retomemos ahora el grafo del ejemplo del envío de mails. Ahora sabemos calcular la probabilidad de que el mail esté entregado después de n pasos... pero hay algo que podemos notar sin necesidad de calcular nada: *una vez entregado, no hay vuelta atrás.*

¿Hay otros estados con propiedades especiales como esta?



- Una vez que el mail está en “Rebotado”, ¿puede volver a “Listo”?
- ¿Qué tan probable es, partiendo de un estado, **volver a pasar por él**?

Estados especiales




Es evidente que el estado “Entregado” es especial ya que la cadena, una vez que llega a este estado, no sale de él. Esto es lo que llamamos un *estado absorbente*.

Definición

Un estado i es **absorbente** si $m_{ii} = P(X_{n+1} = i \mid X_n = i) = 1$.

Relación entre estados



Si vemos ahora el estado “Listo”: ¿puede el mail volver a ese estado desde “En tránsito”? Mirando el grafo, *no hay ningún camino de vuelta*. Esto lleva a una noción más general:


Definición

El estado j es **accesible** desde i (notación: $i \rightarrow j$) si

$$\rho_{ij} = P(\text{la cadena llega a } j \text{ en algún futuro} \mid X_0 = i) > 0.$$

Si existe un camino en el grafo de i a j , entonces $\rho_{ij} \geq P(\text{camino}) > 0$.

Relación entre estados



Definición

Cuando $i \rightarrow j$ **y además** $j \rightarrow i$, decimos que i y j se **comunican**: $i \leftrightarrow j$.

- $T \rightarrow E$ pero $E \not\rightarrow T \Rightarrow$ no se comunican.
- $T \leftrightarrow R \Rightarrow$ se comunican.
- $L \rightarrow T$ pero $T \not\rightarrow L \Rightarrow$ no se comunican.

Transitorios y recurrentes

Entonces podemos tener estados que se comuniquen o que sean accesibles desde algún otro estado. ¿Que pasará entonces si partimos de un estado i y queremos volver? ¿Qué tan probable es volver a i ?

Definición

Sea i un estado cualquiera. Llamemos

$$\rho_{ii} = P(\text{la cadena vuelve a } i \text{ en algún futuro} \mid X_0 = i).$$

Decimos que i

- es **transitorio** si $\rho_{ii} < 1$ (es decir, siempre existe un camino que sale de i y no vuelve).
- es **recurrente** si $\rho_{ii} = 1$ (la cadena siempre vuelve).

Todo estado absorbente es recurrente (con $\rho_{ii} = 1$ trivialmente siempre vuelvo a i).

Clasificación de estados


Estas dos últimas definiciones nos permiten dar una *clasificación de estados* para las Cadenas de Markov, ya que todos los estados son transitorios o recurrentes.

Clasificación de estados

Los estados de una Cadena de Markov se clasifican como:

- **Transitorios:** si $\rho_{ii} < 1$ (podés salir y no garantizás volver).
- **Recurrentes:** si $\rho_{ii} = 1$ (siempre volvés).
 - ▶ **Absorbente:** caso especial con $m_{ii} = 1$ (ni siquiera podés salir).

Volviendo al ejemplo del mail



Estado	Tipo	¿Por qué?
L	transitorio	no hay vuelta desde T
T	transitorio	eventualmente cae en E
R	transitorio	eventualmente cae en E
E	recurrente	absorbente


¿Cómo identificar estados recurrentes?

Ahora bien, para clasificar los estados dependemos de calcular para cualquier estado i la probabilidad

$$\rho_{ii} = P(\text{la cadena vuelve a } i \text{ en algún futuro} \mid X_0 = i)$$

y calcular ρ_{ii} directamente puede ser engorroso...

Veamos esto en un ejemplo nuevo:



Si quisiéramos calcular

$$\rho_{AA} = P(\text{la cadena vuelve a } A \text{ en algún futuro} \mid X_0 = A)$$

se complica por el loop que tenemos en el estado B: para calcular la probabilidad de volver a A partiendo de A deberíamos calcular la probabilidad de cada uno de los caminos posibles para volver a A y sumar todas esas probabilidades. Pero tenemos infinitos posibles caminos y no siguen ningún patrón sencillo:

- Caminos de 3, 4 y 5: una única opción (recorrer el triángulo una vez y transitar el loop 0/1/2 veces)
- Camino de 6: dos posibilidades
- Camino de 9: 3 posibilidades
- ...

y además tenemos que sumar todo esto armando una serie súper compleja...

Como el cálculo de ρ_{ii} es tan complejo (y sólo viendo un ejemplo de 3 estados ya se complica), es necesario encontrar otra forma de poder clasificar todos los estados de una Cadena de Markov sin encontrarnos con una complejidad tan grande.


Para ello vamos a reducirnos a estudiar el caso en el que tengamos un espacio de estados **finito** y vamos a incorporar dos herramientas que nos permiten identificar recurrentes y transitorios de forma sencilla: los **conjuntos cerrados** y los **conjuntos irreducibles**.

Conjunto cerrado

Definición

Un conjunto de estados $C \subseteq S$ es **cerrado** si es imposible salir de él:

$$i \in C, j \notin C \implies p(i, j) = 0 \quad (i \nrightarrow j).$$



$\{E\}$ es cerrado. También $\{T, R, E\}$ es cerrado. ¿Lo es $\{L, T\}$?

Conjunto irreducible


Observemos que no todo conjunto cerrado es igual: en $\{T, R, E\}$, el estado E “atrapa” a la cadena y los demás no pueden volver desde allí.

Formalizando esta idea aparece el concepto de conjuntos *irreducibles*.

Definición

Un conjunto cerrado C es **irreducible** si todos sus estados se comunican entre sí:

$$\forall i, j \in C : i \leftrightarrow j.$$



$\{E\}$ es irreducible (un solo estado). $\{T, R, E\}$ es cerrado pero **no** irreducible: $E \not\leftrightarrow T$.

Teorema para estados recurrentes


Con esas sencillas definiciones podemos obtener nuestra primera herramienta para poder identificar estados recurrentes.

Teorema

Si C es un conjunto **finito**, **cerrado** e **irreducible**, entonces todos los estados en C son **recurrentes**.

Intuición: la cadena queda atrapada dentro de este conjunto (por ser cerrado) y todos los estados que están dentro están conectados entre sí (por ser irreducible), así que siempre vuelve a cada uno de ellos.

Ejemplo del mail: $\{E\}$ es finito, cerrado e irreducible $\Rightarrow E$ es recurrente. $\{T, R\}$ también es finito e irreducible ($T \leftrightarrow R$), pero **no** es cerrado ($T \rightarrow E \notin \{T, R\}$), por lo que el teorema *no aplica* y de hecho T y R son transitorios.



Teorema de clasificación

Finalmente llegamos al resultado más importante de clasificación.

Teorema

*Si el espacio de estados S es **finito**, entonces*

$$S = T \cup R_1 \cup R_2 \cup \cdots \cup R_n$$

*donde T es un conjunto de estados transitorios y cada R_i es un conjunto **cerrado e irreducible** de estados recurrentes.*

¿Por qué nos sirve este teorema? ¿Soluciona el problema de clasificar los estados?

Con $|S|$ finito, **alcanza con identificar los conjuntos irreducibles** en el grafo:


- Los estados **dentro** de esos conjuntos son **recurrentes**.
- Los estados **fuera** son **transitorios**.

Ya no necesitamos calcular ρ_{ii} directamente.

Ejemplo de clasificación

Ejercicio en clase

En el siguiente grafo asociado a una Cadena de Markov, identificar los conjuntos cerrados e irreducibles y clasificar todos los estados.



¿Qué pasa después de muchos pasos?

Hasta ahora estudiamos cómo se mueve una cadena paso a paso y vimos que M^m nos da las probabilidades a m pasos.

Pensando en cadenas que evolucionan en tiempo **infinito**, surgen preguntas naturales:

- ¿Se estabiliza la cadena en algún estado?
- ¿Salta entre estados sin ningún patrón?
- ¿La **distribución de probabilidades** converge a algo?

Para responder estas preguntas necesitamos un lenguaje más formal.

Distribución de la cadena

Definición

Una **distribución** de la cadena en el momento n es un vector fila $q^{(n)}$ con $|S|$ componentes donde

$$q_j^{(n)} = P(X_n = j).$$

Como es una distribución de probabilidades: todas las componentes son no negativas y suman 1.

Ejemplo

Si la cadena arranca siempre desde el estado i (como es el caso de la cadena asociada al envío de mail), entonces $q^{(0)} = e_i^t$ (vector canónico).

Entonces, la pregunta del comportamiento límite de la cadena se traduce en:
¿qué le pasa a $q^{(n)}$ cuando $n \rightarrow \infty$?

¿Qué pasa con los estados transitorios en el infinito?

Recordemos: i es transitorio si $\rho_{ii} < 1$, es decir, existe una chance de salir y nunca volver.

Por la Propiedad Markoviana, cada vez que volvemos a i la situación se “resetea”:

$$P(\text{volver al menos 1 vez}) = \rho_{ii}$$

$$P(\text{volver al menos 2 veces}) = P(\text{volver al menos 1 vez}) \\ * P(\text{volver al menos 1 vez})$$

$$= \rho_{ii} \cdot \rho_{ii} = \rho_{ii}^2$$

$$\vdots$$

$$P(\text{volver al menos } k \text{ veces}) = \rho_{ii}^k$$

Como $\rho_{ii} < 1$, cuando $k \rightarrow \infty$:


$$\rho_{ii}^k \rightarrow 0.$$

Los estados transitorios **desaparecen** a largo plazo: la probabilidad de visitarlos tiende a 0.

Estados recurrentes: ¿converge la distribución?

Para los estados recurrentes ($\rho_{ii} = 1$) la cadena vuelve infinitas veces. Pero eso no garantiza que la distribución converja.

Ejemplo:



La matriz para esta cadena es:

$$M = \begin{pmatrix} 0 & 1 \\ 1 & 0 \end{pmatrix}$$


y consideremos que siempre empezamos en el estado A .

Entonces, en este caso tenemos que el vector distribución inicial es

$$q^{(0)} = (1, 0)$$

Estados recurrentes: ¿converge la distribución?

Ejemplo:



Veamos cómo se comporta la cadena:

$$q^{(0)} = (1, 0)$$

$$q^{(1)} = q^{(0)} * M = (1, 0) * \begin{pmatrix} 0 & 1 \\ 1 & 0 \end{pmatrix} = (0, 1)$$

$$q^{(2)} = q^{(1)} * M = (0, 1) * \begin{pmatrix} 0 & 1 \\ 1 & 0 \end{pmatrix} = (1, 0)$$


$$q^{(3)} = q^{(2)} * M = (1, 0) * \begin{pmatrix} 0 & 1 \\ 1 & 0 \end{pmatrix} = (0, 1)$$

$$\vdots$$

La distribución oscila indefinidamente, por lo que *no converge*.

Estados recurrentes: ¿converge la distribución?

Veamos ahora este otro **ejemplo**:



La matriz para esta cadena es:

$$M = \begin{pmatrix} 0,7 & 0,3 \\ 0,3 & 0,7 \end{pmatrix}$$

y, como antes, consideremos que siempre empezamos en el estado A . Entonces, en este caso tenemos que el vector distribución inicial es

$$q^{(0)} = (1, 0)$$

Estados recurrentes: ¿converge la distribución?


Entonces para este caso vamos a tener las siguientes distribuciones $q^{(n)}$:

n	$q^{(n)}$
0	(1.0000, 0.0000)
1	(0.7000, 0.3000)
2	(0.5800, 0.4200)
3	(0.5320, 0.4680)
4	(0.5128, 0.4872)
$\vdots$	$\vdots$
100	(0.5000, 0.5000)

La distribución converge a $q = (0.5, 0.5)$.

Pero, ¿por qué en este caso sí converge y en el anterior no?

Período de un estado



Desde el estado A , puedo volver en $2, 4, 6, \dots$ pasos, pero *nunca en una cantidad impar*. Esto está relacionado con algo que llamamos **período**:

Definición

El **período** de un estado i es

$$d(i) = \text{mcd}\{n \geq 1 : m_{ii}^{(n)} > 0\}.$$

En el ejemplo: $d(1) = \text{mcd}\{2, 4, 6, \dots\} = 2$.


Definición

Un estado i es **aperiódico** si $d(i) = 1$.

¿Cómo reconocer un estado aperiódico?

Dos formas sencillas:


- 1 El estado tiene un **lazo** (puedo volver en 1 paso, luego $d(i) = 1$).
- 2 Se puede volver al estado por **dos caminos de longitudes coprimas**.



El estado A tiene un lazo (longitud 1) y un camino $A \rightarrow C \rightarrow B \rightarrow A$ (longitud 3): $\text{mcd}(1, 3) = 1 \Rightarrow A$ es aperiódico.

Una distribución *especial*


Volvamos de nuevo al **ejemplo**:



Habíamos visto que para este ejemplo para la distribución $q^{(0)} = (1, 0)$ la cadena converge a una distribución $q = (0.5, 0.5)$.

¿Qué pasa si arrancamos desde esta distribución?

Una distribución *especial*



Veamos cómo se comporta la cadena:

$$q^{(0)} = (0.5, 0.5)$$

$$q^{(1)} = q^{(0)} * M = (0.5, 0.5) * \begin{pmatrix} 0,7 & 0,3 \\ 0,3 & 0,7 \end{pmatrix} = (0.5, 0.5) = q^{(0)}$$

$$q^{(2)} = q^{(1)} * M = q^{(0)} * M = q^{(0)}$$

$$\vdots$$

$$q^{(n)} = q^{(0)}$$

Entonces, la distribución *no se modifica a lo largo del tiempo...*

Distribución estacionaria

Esto no es un comportamiento extraño, lo que está pasando es que la distribución $q = (0.5, 0.5)$ es una distribución invariante para la cadena:

Definición

Una distribución π es **estacionaria** (o invariante) si

$$\pi M = \pi.$$

Es decir, es una distribución que no cambia al aplicarle la matriz de transición.

La distribución estacionaria de una Cadena de Markov es una distribución de equilibrio para el sistema.

Cálculo de la distribución estacionaria

¿Cómo calcularla?

Para hallar la distribución estacionaria π de una Cadena de Markov debemos resolver el sistema $\pi M = \pi$ con la condición $\sum_j \pi_j = 1$.

Para el ejemplo de antes, $M = \begin{pmatrix} 0,7 & 0,3 \\ 0,3 & 0,7 \end{pmatrix}$ y el sistema $\pi M = \pi$ queda:

$$\begin{cases} 0,7 \pi_1 + 0,3 \pi_2 = \pi_1 \\ 0,3 \pi_1 + 0,7 \pi_2 = \pi_2 \\ \pi_1 + \pi_2 = 1 \end{cases}$$

De las dos primeras ecuaciones: $\pi_1 = \pi_2$. Reemplazando en la tercera:

$$\pi = (0.5, 0.5)$$

Lo que coincide con lo visto antes.

Cadenas de Markov *ergódicas*

En este momento podrían surgirnos ciertas preguntas naturales:

- ya vimos que no siempre convergen las CM, ¿cuándo puedo garantizar que converge una Cadena de Markov?
- en el ejemplo que vimos, partimos de dos caminos y llegamos a la distribución estacionaria, ¿siempre que converge lo hace a una distribución de este estilo? ¿es única esta distribución?

Las respuestas a estas dudas no vamos a poder responderlas sólo con esta materia (necesitaríamos mucho más contenido y más profundo)... Pero sí podemos encontrar una respuesta a estas dudas para *un tipo especial de Cadenas de Markov*:

Definición

Una cadena de Markov es ***ergódica*** si es:

- ***irreducible***: todos los estados se comunican entre sí,
- ***aperiódica***: todos los estados tienen período 1.

Teorema de convergencia

Entonces, para las Cadenas de Markov ergódicas tenemos el siguiente resultado:

Teorema

*Si una cadena de Markov es **irreducible** y **aperiódica**, entonces existe una única distribución estacionaria π y para cualquier distribución inicial $q^{(0)}$:*

$$q^{(n)} \xrightarrow{n \rightarrow \infty} \pi.$$

Este teorema resuelve nuestras dudas para las **CM ergódicas**: existe una **distribución estacionaria**, que es **única** y, *sin importar de dónde arranquemos*, **la distribución converge siempre a la misma π** .